

OLIST MARKETPLACE ANALYTICS

Growth, Seller Onboarding & Fulfilment

Olist 市场增长、卖家入驻与履约分析

Bilingual Project Master Plan | 双语项目总计划

Updated: 29 July 2026 | 更新日期: 2026年7月29日

Status: New flagship confirmed; GA4 work retained as a mini technical case.

状态: 新主项目已确认; 现有 GA4 工作保留为迷你技术案例。

1. 最终决定 / Final Decision

主项目改为 Olist Marketing Funnel + Brazilian E-Commerce 两个官方数据集的联合分析。这个方向比单独做常见的销售 Dashboard 更完整：它把卖家获客、成交、上线销售、配送和评价串成一条业务生命周期。

The flagship project combines Olist's official Marketing Funnel and Brazilian E-Commerce datasets. It goes beyond a standard sales dashboard by connecting seller acquisition, deal closure, seller activation, order performance, delivery, and reviews.

- 主项目 / Olist Marketplace Growth, Seller Onboarding & Fulfilment Analytics
- 迷你技术案例 / Retain the three completed GA4 BigQuery SQL files to demonstrate nested data and UNNEST
- **Python/ML 证明** / Use the existing H-SMOTE FYP; do not force machine learning into Olist version 1
- **Excel 准备** / Complete a separate compact Excel interview exercise

真实取舍：Olist 是公开且常见的数据集，所以竞争力不会来自数据集名字，而会来自跨数据集 seller_id 连接、正确的数据粒度、避免 JOIN 重复计算、数据质量验证，以及可执行的商业建议。

Honest trade-off: Olist is public and commonly used. Differentiation must come from the cross-dataset seller_id bridge, correct grains, fan-out prevention, data-quality validation, and actionable recommendations.

2. 数据在哪里拿 / Where to Get the Data

只下载以下两个 Olist 官方 Kaggle 数据集。不要使用别人已经清洗、合并或添加特征的版本。

Download only these two official Olist Kaggle datasets. Do not use third-party cleaned, merged, or feature-engineered copies.

官方下载入口 / Official Download Pages

[1\) Brazilian E-Commerce Public Dataset by Olist](#)

[2\) Marketing Funnel by Olist](#)

数据包 / Package	内容 / Contents	连接键 / Bridge
Brazilian E-Commerce	约100k订单；订单、商品、付款、客户、卖家、配送和评价	order_id, customer_id, product_id, seller_id
Marketing Funnel	约8k MQL 与842个成交记录；来源、首次联系、成交日期和卖家资料	mql_id; seller_id links to e-commerce

下载后应有的11个 CSV / Expected 11 CSV Files

类别 / Group	CSV 文件 / CSV File	一行代表什么 / Grain
E-commerce	olist_orders_dataset.csv	一张订单 / one order
E-commerce	olist_order_items_dataset.csv	订单中的一个商品行 / one order item
E-commerce	olist_order_payments_dataset.csv	一笔订单付款记录 / one payment record

类别 / Group	CSV 文件 / CSV File	一行代表什么 / Grain
E-commerce	olist_order_reviews_dataset.csv	一条订单评价 / one review record
E-commerce	olist_customers_dataset.csv	一张订单对应的客户ID / one order-level customer ID
E-commerce	olist_products_dataset.csv	一个商品 / one product
E-commerce	olist_sellers_dataset.csv	一个卖家 / one seller
E-commerce	olist_geolocation_dataset.csv	一个邮编坐标记录 / one postcode coordinate record
E-commerce	product_category_name_translation.csv	一个葡语至英语类别映射 / one category translation
Marketing	olist_marketing_qualified_leads_dataset.csv	一个 MQL / one marketing-qualified lead
Marketing	olist_closed_deals_dataset.csv	一个成功成交的 MQL / one closed MQL deal

3. 项目到底解决什么 / Business Problem

项目目标不是描述所有数据，而是帮助 marketplace 的增长与运营团队判断：哪些获客渠道带来能够真正成交、上线销售，并持续创造高质量订单的卖家？哪些卖家虽然订单高，却有配送延迟或低评分风险？

The project helps marketplace growth and operations teams identify which acquisition channels produce sellers who close, activate, generate valuable orders, and fulfil them reliably—and which high-volume sellers create delivery or review risks.

核心问题 / Core Questions

- 各来源带来多少 **MQL**，成交率是多少？ / How many MQLs and closed deals does each origin produce?
- 从首次联系到成交需要多少天？ / How long does lead-to-close take?
- 成交卖家从 **won_date** 到第一张订单需要多少天？ / How long does seller activation take from won_date to first sale?
- 哪些来源带来的卖家拥有较高订单量、**GMV**和客单价？ / Which origins produce sellers with stronger orders, GMV, and AOV?
- 哪些卖家订单高但延迟率高或评分低？ / Which sellers have high volume but high late-delivery rates or low ratings?
- 配送延迟是否伴随较低评分？ / Is late delivery associated with lower review scores?

限制：项目报告关联，不声称营销来源或配送延迟一定造成某个结果。

Limitation: the analysis reports associations and does not claim causal effects.

4. 数据流程与技术 / Workflow and Tools

Raw CSV → BigQuery raw tables → SQL profiling → staging views → analytical marts → quality checks → Power BI semantic model → four report pages → README and interview story

原始 CSV → BigQuery 原始表 → SQL 数据检查 → staging 整理层 → 分析数据集市 → 质量检查
→ Power BI 语义模型 → 四页报告 → README 与面试表达

工具 / Tool	在项目中的职责 / Responsibility
BigQuery + GoogleSQL	载入11张关系表；检查、清洗、JOIN、汇总、建模和验证
Power BI + DAX	建立星型模型、动态KPI、筛选、drill-through和四页互动报告
Git + GitHub	保存SQL、数据字典、决策、README与版本历史
Python/pytest（轻量支持）	可选地自动验证导出表；Python/ML能力主要由H-SMOTE FYP证明
Excel	独立的面试实务练习，不承担主项目的数据工程

必须避免的 JOIN 错误 / Critical Join Rule

orders、order_items、payments 和 reviews 不是全部一对一。必须先分别汇总 order_items 和 payments，再连接订单；否则一个订单有多个商品与多笔付款时，GMV或付款金额会被乘大。

Orders, items, payments, and reviews are not all one-to-one. Aggregate items and payments separately before joining to orders; otherwise multi-item and multi-payment orders can multiply GMV or payment value.

5. 第一版交付成果 / Version 1 Deliverables

- 固定15个核心 SQL 文件，分成5个阶段 / Exactly 15 core SQL files across five stages
- 4个可供 Power BI 使用的分析 marts / Four Power BI-ready analytical marts
- 2个最终数据质量与对账文件 / Two final data-quality and reconciliation files
- 1个 Power BI .pbix: 4个主报告页面 + 1个 drill-through 详情页面 / One Power BI .pbix with four main report pages plus one drill-through detail page
- 双语 README、数据字典、架构和限制说明 / Bilingual README, data dictionary, architecture, and limitations
- 3分钟英文项目介绍与常见面试问答 / A three-minute English walkthrough and common interview Q&A

不纳入第一版 / Excluded from Version 1

- 评论文字 NLP / Review-text NLP
- 机器学习、预测或推荐系统 / Machine learning, forecasting, or recommendation systems
- 复杂地理地图 / Complex geospatial mapping
- RFM、churn 与 Streamlit / RFM, churn, and Streamlit

6. SQL完整蓝图：固定15个文件 / Exact 15-File SQL Blueprint

SQL 不是15道互不相关的练习，而是一条可追溯的数据管道。每个文件必须有清楚的输入、输出、grain、业务用途和验证方法。

The fifteen SQL files form one traceable pipeline rather than fifteen unrelated exercises. Every file must state its inputs, output grain, business purpose, and validation method.

#	SQL 文件 / File	输出粒度 / Output Grain	用途与SQL重点 / Purpose and SQL Evidence
1	00_source_profiling/01_table_inventory.sql	每张来源表一行 / one row per source table	COUNT、COUNT DISTINCT、MIN/MAX、UNION ALL；记录11表行数、日期范围和候选键
2	00_source_profiling/02_source_quality_and_keys.sql	每项检查一行 / one row per quality check	CTE、HAVING、NOT EXISTS；检查空值、重复主键、孤儿外键、未知状态和异常日期
3	01_staging/01_stg_orders.sql	一张订单 / one order	清理时间字段；LEFT JOIN customers；CASE、COALESCE、DATE_DIFF；建立 delivered、late、cancelled flags
4	01_staging/02_stg_order_items.sql	一个订单商品 / one order item	JOIN products、category translation、sellers；建立 item_value、freight_value 与商品类别
5	01_staging/03_stg_order_payments.sql	一张订单 / one order	先按 order_id GROUP BY；SUM payment_value、付款次数、分期与付款类型，避免JOIN放大
6	01_staging/04_stg_marketing_funnel.sql	一个MQL / one MQL	MQL LEFT JOIN closed deals；保留未成交 leads；deal flag、lead-to-close days 与 seller_id
7	02_marts/01_mart_orders.sql	一张订单 / one order	多个CTE先汇总 items/payments；ROW_NUMBER 处理多评价；整合订单、配送、付款、评价和客户地区
8	02_marts/02_mart_order_seller.sql	订单×卖家 / one order-seller	按 order_id + seller_id 汇总商品金额、运费与件数；为卖家表现分析提供安全grain

#	SQL 文件 / File	输出粒度 / Output Grain	用途与SQL重点 / Purpose and SQL Evidence
9	02_marts/03_mart_marketing_funnel.sql	一个MQL / one MQL	输出来源、首次联系、成交、成交天数与卖家ID，供Power BI漏斗使用
10	02_marts/04_mart_seller_lifecycle.sql	一个成交卖家 / one closed seller	funnel JOIN seller首单与表现；MIN、DATE_DIFF；activation flag、days-to-first-sale、累计GMV
11	03_analysis/01_acquisition_channel_quality.sql	月份×来源 / month-origin	条件聚合、SAFE_DIVIDE、LAG；比较MQL、成交、激活卖家与月度变化
12	03_analysis/02_seller_activation_performance.sql	一个卖家 / one seller	RANK或NTILE；找出快速激活、高GMV、延迟率高或低评分的卖家
13	03_analysis/03_delivery_review_analysis.sql	分析群组 / analytical segment	CASE、AVG、COUNTIF、SAFE_DIVIDE；比较准时与延迟订单的配送时间和评分，只报告关联
14	04_quality_checks/01_join_fanout_reconciliation.sql	每项对账一行 / one row per reconciliation	比较JOIN前后行数、distinct orders、GMV和付款值；所有意外差异必须解释
15	04_quality_checks/02_final_kpi_validation.sql	每个KPI一行 / one row per KPI	raw→staging→mart→Power BI数字核对；输出pass/fail与差异，作为发布闸门

五个阶段的完成条件 / Stage Exit Criteria

阶段 / Stage	文件数 / Files	完成条件 / Exit Criterion
00 Source Profiling	2	能解释11张表、候选键、关系、空值与重要质量问题
01 Staging	4	字段类型、日期、flags与基础关系稳定；不改变原始含义
02 Marts	4	每张mart只有一个明确grain，JOIN不会放大金额或订单
03 Analysis	3	回答增长、卖家激活、履约与评价三个核心业务问题
04 Quality Checks	2	所有关键KPI可从raw追溯；未通过检查不得进入Power BI

7. SQL要做到多深 / Required SQL Depth

层级 / Level	必须展示 / Required Evidence	在本项目哪里出现 / Where It Appears
基础	SELECT、WHERE、GROUP BY、ORDER BY、aliases、COUNT DISTINCT	profiling、staging、所有分析
中级	CTE、CASE WHEN、COALESCE、CAST、日期函数、条件聚合、SAFE_DIVIDE	staging、marts、business analysis
JOIN	INNER JOIN、LEFT JOIN、聚合后再JOIN、anti-join/NOT EXISTS、cardinality说明	items、orders、funnel、seller lifecycle、quality checks
进阶	ROW_NUMBER、LAG、RANK/NTILE、多个CTE、分层marts	review去重、月度变化、卖家排序
质量	重复键、孤儿键、行数对账、金额对账、pass/fail发布闸门	两个profiling文件与两个quality文件

JOIN使用规则 / JOIN Rules

- **LEFT JOIN** 是主要连接：保留所有订单或所有MQL，即使右表没有匹配 / Use LEFT JOIN to preserve every order or MQL when the right-side record may be missing
- **INNER JOIN** 只在业务上要求必须匹配时使用 / Use INNER JOIN only when a matched record is required by the business grain
- 一对多表必须先汇总到目标grain再连接 / Aggregate one-to-many tables to the target grain before joining
- 每次JOIN前写出左表grain、右表grain和预期cardinality / State the left grain, right grain, and expected cardinality before every join
- 用**NOT EXISTS**检查孤儿外键；用JOIN前后COUNT与SUM检查fan-out / Use NOT EXISTS for orphan keys and compare counts and sums before and after joins
- 不会为了显得高级而强行使用**RIGHT**、**FULL**、**CROSS**或**SELF JOIN** / Do not force RIGHT, FULL, CROSS, or SELF JOIN when the business problem does not require them

金额术语必须准确 / Correct Financial Terminology

Olist 数据包含商品价格、运费和付款金额，但没有Olist佣金、成本或利润。因此项目使用 GMV / Item Sales Value、Payment Value 和 Freight Value；不能把这些直接称为Olist公司的revenue或profit。

The dataset contains item prices, freight, and payment values but not Olist commissions, costs, or profit. Use GMV / Item Sales Value, Payment Value, and Freight Value; do not present them as Olist company revenue or profit.

8. Power BI完整规格 / Power BI Scope and Depth

最终只建立一个专业的 .pbix 报告，不用页面数量堆砌。范围固定为4个主报告页面加1个隐藏的 drill-through 详情页面。发布到Power BI Service后，可选建立1个真正的单页dashboard；Desktop 中的多页面成品技术上叫report。

Build one professional .pbix report: four main pages plus one hidden drill-through detail page. If Power BI Service is available, optionally create one true single-page dashboard. The multi-page Desktop deliverable is technically a report.

数据模型 / Semantic Model

模型表 / Model Table	Grain	来源 / Source	职责与关系 / Role and Relationships
FactOrders	一张订单	mart_orders	订单、配送、评价、客户地区；连接DimDate
FactOrderSeller	订单×卖家	mart_order_seller	卖家订单、GMV与运费；连接DimDate和DimSeller
FactMQL	一个MQL	mart_marketing_funnel	来源、成交与lead-to-close；连接DimDate和DimOrigin
DimSeller	一个成交卖家	mart_seller_lifecycle	来源、成交日、首单日、activation；过滤FactOrderSeller
DimDate	一天	DAX日期表	连续日期、月、季度、年份；支持趋势与time intelligence
DimOrigin	一个来源渠道	FactMQL去重	统一渠道名称；过滤FactMQL并通过DimSeller解释卖家来源

模型必须是一对多、单向筛选为主。禁止直接把11张raw CSV全部互相连接。每个关系都要检查 cardinality，不允许many-to-many关系被静默接受。

Use primarily one-to-many, single-direction relationships. Do not connect all eleven raw CSV files directly. Validate every relationship cardinality and do not silently accept many-to-many relationships.

4个主页面 + 1个详情页 / Four Main Pages + One Detail Page

页面 / Page	核心问题 / Main Question	主要内容 / Required Visuals and Interactions
1. Executive Overview	平台整体表现怎样？	KPI cards: Orders、GMV、AOV、Active Sellers、On-Time Rate、Avg Review；月度趋势；状态分布；关键结论
2. Acquisition Funnel	哪些来源带来成交并激活的卖家？	MQL→Closed Deal→Activated Seller漏斗；origin close rate；lead-to-close与activation days；日期与origin slicers
3. Seller Performance	哪些卖家创造价值，哪些存在风险？	GMV/订单排名；GMV vs late-rate scatter；activation cohort；条件格式风险表；点击进入seller drill-through
4. Fulfilment & CX	配送表现如何影响客户体验？	On-time/late rate、delivery days、freight-to-GMV、review score；按州和状态比较；只报告association

页面 / Page	核心问题 / Main Question	主要内容 / Required Visuals and Interactions
5. Seller Detail	单个卖家的完整情况是什么？	隐藏drill-through页；卖家KPI、月度GMV、订单状态、配送与评分；返回按钮

DAX深度：约18个核心Measures / DAX Depth: About 18 Core Measures

类别 / Group	核心 Measures / Core Measures
Growth Funnel	Total MQLs; Closed Deals; Close Rate; Median Lead-to-Close Days; Activated Sellers; Activation Rate; Median Days to First Sale
Commercial	Total Orders; Active Sellers; GMV; Average Order Value; Orders per Seller; Total Freight; Freight-to-GMV Ratio
Fulfilment & CX	Delivered Orders; On-Time Delivery Rate; Late Delivery Rate; Average Delivery Days; Average Review Score

- 必须使用**DISTINCTCOUNT**、**SUM**、**DIVIDE**、**CALCULATE**、**FILTER**与**MEDIANX** / Use DISTINCTCOUNT, SUM, DIVIDE, CALCULATE, FILTER, and MEDIANX
- 需要时使用**USERELATIONSHIP**处理**first-contact**、**won-date**或**order-date** / Use USERELATIONSHIP when a fact requires alternate date relationships
- 使用**RANKX**或**SQL rank**展示卖家排名，但不得把排名当成因果结论 / Use RANKX or SQL ranking for seller comparison without causal claims
- 所有**KPI**必须与**SQL validation**结果一致 / Every KPI must match the SQL validation output

Power BI必须具备的互动深度 / Required Interactivity

- 日期、**origin**、**seller state**和**order status slicers** / Date, origin, seller-state, and order-status slicers
- **seller drill-through**、**report-page tooltip**和返回按钮 / Seller drill-through, report-page tooltip, and back button
- 交叉筛选、条件格式、动态标题和清楚的**filter context** / Cross-filtering, conditional formatting, dynamic titles, and clear filter context
- 每页最多回答一个主要商业问题，并给出**2至3条**结论 / Each page answers one primary business question and presents two to three conclusions

9. 项目完成与面试标准 / Completion and Interview Standard

范围 / Area	必须能够证明 / Evidence Required
SQL	独立解释15个文件的目的、grain、JOIN选择、窗口函数与验证结果；能修改条件并重新运行
Data Modelling	画出11张raw表关系与Power BI星型模型；解释一对多和fan-out
Power BI	解释4个页面、18个measures、filter context、drill-through与KPI验证方法
Business	提出3至5条有数据证据、注明限制且可执行的建议
English	完成3分钟项目介绍，并回答grain、LEFT JOIN、duplicate、GMV与causation问题

范围 / Area	必须能够证明 / Evidence Required
Portfolio	GitHub含README、SQL、data dictionary、architecture、screenshots和limitations; 不上传大型raw data

完成标准不是SQL全部成功运行就结束。只有当SQL验证通过、Power BI数字一致、商业结论不越界，而且你能自己解释整个流程时，项目才算完成。

The project is complete only when SQL checks pass, Power BI numbers reconcile, claims stay within the data's limits, and you can explain the full workflow independently.

10. 18天完成路线 / 18-Day Build Plan

日期 / Days	工作 / Work	完成标准 / Done When
1-2	下载、解压、11表盘点、主键与粒度；完成SQL 1-2	能用自己的话解释每张表一行代表什么
3-6	完成4个staging文件；SQL 3-6	字段、日期、flags和基础JOIN正确
7-10	完成4个marts；SQL 7-10	数字不会因一对多 JOIN 膨胀
11-12	3个业务分析 + 2个质量检查；SQL 11-15	seller_id 串起获客与销售；最终检查通过
13	建立Power BI星型模型与约18个DAX measures	所有KPI可追溯并与SQL一致
14-16	完成4个主页面 + 1个drill-through页	筛选、tooltip与drill-through正确运行
17	README、架构、数据字典与GitHub整理	陌生人能读懂项目
18	最终QA、截图、洞察和面试讲解	可独立演示完整流程

以每天5小时计算：10天只能完成赶工版；14-18天可完成可靠的第一版；21-25天可达到较好的面试准备状态。

At five hours per day: ten days gives a rushed draft; 14-18 days gives a reliable version 1; 21-25 days allows stronger interview preparation.

11. 教学规则 / Mentoring Rules

- 基础 **SQL**：我给英文业务题和提示，你先判断并自己写 / Basic SQL: receive an English business task and hints, then write it yourself
- 非基础 **SQL**：我先教结构和例子，你再解释和修改 / Advanced SQL: receive a direct explanation and example, then explain and modify it
- 所有练习必须成为项目文件或直接服务项目 / Every exercise must become a project artifact or directly support one
- 先说明 **grain**，再写 **COUNT** 或 **JOIN** / State the grain before writing COUNT or JOIN
- 不以文件数量假装高级 / Do not inflate the file count to appear advanced
- 每完成一阶段，练一次英文面试表达 / Practise an English interview explanation after each phase

12. 现在马上做什么 / Immediate Next Step

1. 打开两个官方 **Kaggle** 链接并登录 / Open both official Kaggle links and sign in
2. 每个页面点击 **Download**, 得到两个 **ZIP** / Click Download on each page to obtain two ZIP files
3. 先不要改文件名, 也不要打开后合并 / Do not rename, clean, or merge the files yet
4. 把两个 **ZIP** 放到 **D:\olist-marketplace-analytics\data\raw\downloads** / Place both ZIP files in D:\olist-marketplace-analytics\data\raw\downloads
5. 完成后告诉导师“下载好了”并附文件夹截图 / When finished, say “下载好了” and attach a folder screenshot

第一课不是马上 JOIN。第一课是 Data Inventory: 确认11个 CSV 是否齐全、每张表的行数、列数、主键候选和一行代表什么。

Lesson 1 is not a JOIN. It is Data Inventory: verify all eleven CSV files, row counts, column counts, candidate keys, and the grain of each table.